



Insper

Machine Learning



Aula 13 – Redução de dimensionalidade

2020 – Engenharia
Fábio Ayres <fabioja@insper.edu.br>

Redução de dimensionalidade

- Como visualizar um dataset de dimensão $n = 200$?
- Será que em um dataset de dimensão $n = 200$ realmente temos tudo isso de informação independente?
- Como “enxugar” um dataset?

Exemplo





Ideia: projeção

Podemos projetar esses dados em um hiperplano de menor dimensão!

Assim só precisamos guardar:

- A origem do plano
- Os vetores determinando o hiperplano
- As coordenadas de projeção por ponto: $d \ll n$

Exemplo




Aproximações sucessivas

- $d = 0$: não guardo nenhuma coordenada por ponto!
 - Guardo apenas o centroide da nuvem!
- $d > 0$: começo a gerar componentes de projeção por ponto.

$$\hat{x}_i = p + \alpha_{i1}w_1 + \alpha_{i2}w_2 + \cdots + \alpha_{id}w_d$$

Zero-ésima aproximação



Zero-ésima aproximação

- Vamos chamar de \hat{x}_i a aproximação do ponto x_i
- Como temos uma aproximação de um ponto só, $\hat{x}_i = p$ para algum ponto p . Que ponto é esse?

Zero-ésima aproximação

$$\begin{aligned}MSE &= \frac{1}{m} \sum_{i=1}^m \|x_i - p\|^2 = \frac{1}{m} \sum_{i=1}^m (x_i - p)^T (x_i - p) \\&= \frac{1}{m} \sum_{i=1}^m (x_i^T x_i - 2p^T x_i + p^T p)\end{aligned}$$

$$\frac{\partial}{\partial p} MSE = \frac{1}{m} \sum_{i=1}^m -2x_i + 2p = 0$$

$$\Rightarrow p = \frac{1}{m} \sum_{i=1}^m x_i$$

O ponto ótimo
é o centroide!

Próximas aproximações


- Agora vamos descobrir a próxima aproximação:
 $d = 1$
- Vamos remover a zero-ésima aproximação do dataset:

$$x_i \leftarrow (x_i - p)$$

- Nosso dataset (remanescente) tem uma nuvem de pontos cujo centróide é a origem

Próximas aproximações

Vamos aproximar cada ponto do dataset pela sua projeção em uma direção w



Pitágoras:

$$\|x_i\|^2 = \|\hat{x}_i\|^2 + \|\varepsilon_i\|^2$$

$$\Rightarrow \|\varepsilon_i\|^2 = \|x_i\|^2 - \|\hat{x}_i\|^2$$

Próximas aproximações

$$\begin{aligned}
 MSE &= \frac{1}{m} \sum_{i=1}^m \|\varepsilon_i\|^2 = \frac{1}{m} \sum_{i=1}^m (\|x_i\|^2 - \|\hat{x}_i\|^2) \\
 &= \frac{1}{m} \sum_{i=1}^m \|x_i\|^2 - \frac{1}{m} \sum_{i=1}^m \|\hat{x}_i\|^2
 \end{aligned}$$

Portanto,

$$w_1 = \arg \min_w MSE = \arg \max_w \frac{1}{m} \sum_{i=1}^m \|\hat{x}_i\|^2$$

Maximizando as projeções

\hat{x}_i = projeção de x_i na direção w

$$\Rightarrow \hat{x}_i = \left(\frac{w^T x_i}{w^T w} \right) w$$

$$M(w) = \frac{1}{m} \sum_{i=1}^m \|\hat{x}_i\|^2 = \frac{1}{m} \sum_{i=1}^m \hat{x}_i^T \hat{x}_i$$

$$= \frac{1}{m} \sum_{i=1}^m \left(\frac{w^T x_i}{w^T w} \right)^2 w^T w = \frac{1}{m} \sum_{i=1}^m \frac{(w^T x_i)^2}{w^T w}$$

Maximizando as projeções

$$M(w) = \frac{1}{m} \sum_{i=1}^m \frac{(w^T x_i)^2}{w^T w} = \frac{1}{m} \sum_{i=1}^m \frac{w^T x_i x_i^T w}{w^T w}$$

$$\Rightarrow M(w) = \frac{w^T C w}{w^T w}$$

onde

$$C = \frac{1}{m} \sum_{i=1}^m x_i x_i^T$$

Matriz de covariância

linhas

$$X = \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_m^T \end{bmatrix}$$

colunas

$$X^T = \begin{bmatrix} x_1 & x_2 & \cdots & x_m \end{bmatrix}$$

$$\frac{1}{m} X^T X = \frac{1}{m} \begin{bmatrix} x_1 & x_2 & \cdots & x_m \end{bmatrix} \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_m^T \end{bmatrix} = \frac{1}{m} \sum_{i=1}^m x_i x_i^T$$

Logo: $C = \frac{1}{m} X^T X$, que é a matriz de covariância dos dados!

Maximizando as projeções

Portanto, queremos achar w que maximiza

$$M(w) = \frac{w^T C w}{w^T w}$$

E agora?

Autovalores e autovetores

- Imagine o que acontece se w for um autovetor (dentre vários) da matriz C : $Cw = \lambda w$

- Portanto

$$M(w) = \frac{w^T C w}{w^T w} = \lambda \frac{w^T w}{w^T w} = \lambda$$

- Agora temos uma estratégia para maximizar $M(w)$:

$w =$ **autovetor de C** correspondente ao **maior autovalor**

Próximas aproximações?

Repita o processo:

- Remova a aproximação feita até o momento

$$X_k = X - \hat{X}_{k-1}$$

- Calcule a matriz de covariância atual

$$C_k = Cov[X_k] = \frac{1}{m} X_k^T X_k$$

- Calcule o autovetor do maior autovalor da matriz C_k

Principal Component Analysis

Ufa! Se você chegou até aqui, parabéns! Você acabou de derivar o **método das componentes principais**, um dos algoritmos mais importantes da estatística!

Principal Component Analysis

Calcule os parâmetros da PCA:

1. A média \bar{p} das amostras
2. A matriz de covariância C
3. Os d autovetores w_k correspondentes aos maiores autovalores de C

Principal Component Analysis

Agora calcule as **componentes principais** de cada ponto de dados:

1. Remova a média \bar{x} de cada amostra x_i
2. Projete os pontos resultantes nas direções principais

Principal Component Analysis

- Medida de “desempenho”: soma dos autovalores
 - Representa o quanto da variabilidade original do dataset foi capturada no dataset reduzido
- Aplicações
 - Análise das direções: podem indicar os aspectos mais importantes do dataset
 - Compressão: representar aproximadamente o dataset com menos dados
 - Visualização: projetar em 2D ou 3D para observar como os dados se espalham
 - Redução de computação: treinar modelos mais rapidamente sem perder muita qualidade

Principal Component Analysis



Implementações:

- Decomposição por Valores Singulares (SVD: Singular Value Decomposition)
- PCA incremental
- PCA aleatorizada

Estude mais sobre essas técnicas em seu livro texto

Limitações

- Só projeta os pontos em **hiperplanos**
- E se os pontos estão em outras superfícies?



Outras técnicas

Existem técnicas mais sofisticadas para redução de dimensionalidade, que lidam com a não-linearidade:

- Kernel PCA
- Local Linear Embedding
- t-Distributed Stochastic Neighbor Embedding (t-SNE)

The background of the slide is composed of several concentric, partial circular arcs in red and grey, creating a dynamic, layered effect. The word "Insper" is centered within a large, light grey arc on the left side of the image.

Insper